


Codificación de caracteres:

ASCII:

En informática, se conoce como ASCII (pronunciado aski) o Código ASCII a un código de caracteres escritos que se basa en el alfabeto latino, idéntico al empleado por el inglés moderno. Proviene de una renovación o reelaboración del código empleado hasta 1963 en la telegrafía, realizado por el Comité Estadounidense de Estándares (ASA), antecedente del actual ANSI. Su nombre es acrónimo de American Standard Code for Information Interchange o Código Estándar Estadounidense para el Intercambio de Información.



El código ASCII original empleaba 7 bits de información para representar cada uno de los caracteres correspondientes, y un bit adicional para la comprobación de errores para un total de 8 bits, es decir, un byte. No se lo debe confundir con diversos códigos actuales de 8 bits que extienden el ASCII para incorporar signos de otros idiomas distintos al inglés.

Dicho de modo más simple, se trata de una traducción numérica del alfabeto empleado por el inglés, dado que los sistemas informáticos sólo manejan código binario (0-1) como lenguaje para representar sus operaciones lógicas. Así, a cada carácter (letra, signo o incluso espacio en blanco) corresponde en ASCII una cadena numérica de siete bits (siete dígitos entre 0 y 1, es decir, en código binario).

El estándar de ASCII se publicó por primera vez en 1967 y se actualizó por última vez en 1986, llevándolo a su versión contemporánea para 32 caracteres no imprimibles y 95 imprimibles que les siguen en numeración. Se trata de un código empleado casi universalmente por los sistemas informáticos actuales, indispensable para administrar dispositivos de carácter tipográfico, como son los teclados.

Unos ejemplos de formulación ASCII para representar caracteres comunes son los siguientes:

Carácter A: 0100 0001

Carácter C: 0100 0011

Carácter I: 0010 0001

Carácter #: 0010 0011

Carácter /: 0010 1111

Carácter K: 0100 1011

UTF-8:

UTF8 son las siglas de «8-bit Unicode Transformation Format», un formato de codificación de caracteres Unicode e ISO 10646 que, como particularidad, utiliza símbolos de longitud variable. Tiene una serie de características que lo hacen perfecto para codificar tu correos electrónicos y crear una página web.

CODIFICACIÓN CON UTF-8

$$\begin{aligned}\text{ñ (Unicode)} &= \text{U+00F1} \\ &= \overset{0}{0} \overset{0}{0} \overset{0}{0} \overset{0}{0} \overset{F}{1} \overset{1}{1} \overset{1}{0} \overset{0}{0} \overset{0}{0} \overset{1}{1} \\ &\quad \swarrow \quad \searrow \quad \swarrow \quad \searrow \\ &\quad 110x \text{ xxxx} \quad 10xx \text{ xxxx} \\ \text{ñ (UTF-8)} &= \quad 1100 \ 0011 \ 1011 \ 0001 \quad = \text{C3B1}\end{aligned}$$

De hecho, es una de las codificaciones contempladas por el IETF (Internet Engineering Task Force) para todos los protocolos de Internet, que deben especificar qué codificación utilizan para los textos. Por otro lado, el Internet Mail Consortium (IMC) recomienda que todas las aplicaciones de email sean compatibles con este formato.


Usa símbolos de longitud variable. Utiliza una cantidad variable de bytes para representar caracteres, lo que ahorra espacio para los más comunes y garantiza que todos puedan representarse. Así, las representaciones se realizan utilizando de 1 a 4 bytes.

- **1 byte.** Caracteres incluidos en US-ASCII (128 caracteres).
- **2 bytes.** 1920 caracteres que incluyen los caracteres romances más signos diacríticos, y los alfabetos griego, cirílico, copto, armenio, hebreo, árabe, siríaco y Thaana entre otros.
- **3 bytes.** Caracteres del plano básico multilingüe de Unicode, incluyendo los caracteres del grupo CJK: chino, japonés y coreano.
- **4 bytes.** Caracteres del plano suplementario multilingüe: símbolos matemáticos y alfabetos clásicos para uso principalmente académico; y también el plano suplementario ideográfico: caracteres Han de uso poco común.

UTF-8 fue ideado por Kenneth L. Thompson bajo los criterios de diseño de Rob Pike el 2 de septiembre de 1992. Ambos lo implementaron e implantaron en su sistema operativo Plan 9 from Bell Labs. Posteriormente fue oficialmente presentado en la conferencia USENIX en San Diego en enero de 1993. Fue promovido a estándar con el patrocinio de X/Open Joint Internationalization Group (XOJIG) y durante el proceso recibió diferentes nombres como FSS/UTF y UTF-2.

UTF-16:

UTF-16, que significa en ISO/IEC 10646:2003 “UCS Transformation Format for 16 Planes of Group 00”, es una forma de codificación de caracteres UCS y Unicode utilizando símbolos de longitud variable. Está oficialmente definida en el Anexo C de la norma ISO/IEC 10646:2003. También está descrita en el Estándar Unicode (versión 3.0 o superior), al igual que en la RFC 2781 de la IETF.



Sus características principales son:

- Es capaz de representar cualquier carácter Unicode.
- Utiliza símbolos de longitud variable: 1 o 2 palabras de 16 bits por carácter Unicode (2 o 4 bytes). La unidad de información es la palabra de 16 bits.
- Está optimizado para representar caracteres del plano básico multilingüe (BMP) y caracteres del rango U+0000 a U+FFFF. El BMP contiene la gran mayoría de caracteres y sistemas de escritura en uso en la actualidad. Cuando se limita al plano básico multilingüe, UTF-16 puede ser considerado una forma de codificación con símbolos de tamaño fijo (16 bits).
- No superposición: Los símbolos de 1 palabra (16 bits) utilizan un subconjunto de valores que no puede utilizarse en símbolos de 2 palabras (32 bits).

UTF-16 es la evolución de UCS-2, presente en el estándar Unicode hasta la versión 1.1. En UCS-2 cada punto de código se representa por su valor, lo que limitaba su uso al plano básico multilingüe. En la versión 2.0 del Estándar Unicode, la decisión de ampliar el espacio de códigos por encima del código FFFF supuso la necesidad de incluir un nuevo formato que diese soporte a los nuevos planos, 15 y 16, de uso privado. Sin embargo, el estándar no definió todavía ningún punto de código haciendo uso de este mecanismo hasta la versión 3.1.

Tipos de archivos:

JSON:

JSON (acrónimo de JavaScript Object Notation, 'notación de objeto de JavaScript') es un formato de texto sencillo para el intercambio de datos. Se trata de un subconjunto de la notación literal de objetos de JavaScript, aunque, debido a su amplia adopción como alternativa a XML, se considera un formato independiente del lenguaje.

Una de las supuestas ventajas de JSON sobre XML como formato de intercambio de datos es que resulta mucho más sencillo escribir un analizador sintáctico (parser) para él. En JavaScript, un texto JSON se puede analizar fácilmente usando la función `eval()`, algo que (debido a la ubicuidad de JavaScript en casi cualquier navegador web) ha sido fundamental para que haya sido aceptado por parte de la comunidad de desarrolladores AJAX.

En la práctica, los argumentos a favor de la facilidad de desarrollo de analizadores o de sus rendimientos son poco relevantes, debido a las cuestiones de seguridad que plantea el uso de `eval()` y el auge del procesamiento nativo de XML incorporado en los navegadores modernos.[5] Por esa razón, JSON se emplea habitualmente en entornos donde el tamaño del flujo de datos entre cliente y servidor es de vital importancia. De aquí su uso por Yahoo!, Google, Mozilla, etc, que atienden a millones de usuarios, cuando la fuente de datos es explícitamente de fiar y donde no es importante el hecho de no disponer de procesamiento XSLT para manipular los datos en el cliente.


Los tipos de datos disponibles con JSON son:

- **Números:** Se permiten números negativos y opcionalmente pueden contener parte fraccional separada por puntos. Ejemplo: 123.456
- **Cadenas:** Representan secuencias de cero o más caracteres. Se ponen entre doble comilla y se permiten cadenas de escape. Ejemplo: "Hola"
- **Booleanos:** Representan valores booleanos y pueden tener dos valores: true y false
- **null:** Representan el valor nulo.
- **Array:** Representa una lista ordenada de cero o más valores los cuales pueden ser de cualquier tipo. Los valores se separan por comas y el vector se mete entre corchetes. Ejemplo ["juan","pedro","jacinto"]
- **Objetos:** Son colecciones no ordenadas de pares de la forma <nombre>:<valor> separados por comas y puestas entre llaves. El nombre tiene que ser una cadena entre comillas dobles. El valor puede ser de cualquier tipo. Ejemplo:

```
{
  "departamento":8,
  "nombredepto":"Ventas",
  "director": "Juan Rodríguez",
  "empleados":[
    {
      "nombre":"Pedro",
      "apellido":"Fernández"
    },{
      "nombre":"Jacinto",
      "apellido":"Benavente"
    }
  ]
}
```

XML:

Un archivo .xml (Extensible Markup Language) es, básicamente, un formato de archivo utilizado para almacenar y transportar datos. A diferencia de otros tipos de archivos, un XML está diseñado para ser legible tanto por humanos como por máquinas. Piensa en él como una especie de contenedor donde puedes almacenar información de forma organizada, usando etiquetas que describen los datos.



Por ejemplo, un archivo XML puede contener información sobre productos, clientes, facturas o cualquier otro tipo de datos que necesiten ser almacenados de forma estructurada.

Ventajas de los archivos .xml:


- Son fáciles de compartir y mover entre plataformas.
- Permiten organizar la información de manera jerárquica.
- Los usan muchos programas y sistemas para intercambiar datos.

XML proviene de un lenguaje inventado por IBM en la década de los 70's, llamado GML (Generalized Markup Language), que surgió por la necesidad que tenía la empresa de almacenar grandes cantidades de información y compartirla en otros SO y plataformas. Este lenguaje gustó a la ISO, por lo que en 1986 trabajaron para normalizarlo, creando SGML (Standard Generalized Markup Language), capaz de adaptarse a un gran abanico de problemas. A partir de él se han creado otros sistemas para almacenar información.

En el año 1989 Tim Berners Lee creó la web, y junto con ella el lenguaje HTML. Este lenguaje se definió en el marco de SGML y fue de lejos la aplicación más conocida de este estándar. Los navegadores web sin embargo siempre han puesto pocas exigencias al código HTML que interpretan y así las páginas web son caóticas y no cumplen con la sintaxis. Estas páginas web dependen fuertemente de una forma específica de lidiar con los errores y las ambigüedades, lo que hace a las páginas más frágiles y a los navegadores más complejos.

CVS:

Las siglas CSV vienen del inglés "Comma Separated Values" y significan valores separados por comas. Dicho esto, un archivo CSV es cualquier archivo de texto en el cual los caracteres están separados por comas, haciendo una especie de tabla en filas y columnas. Las columnas quedan definidas por cada punto y coma (;), mientras que cada fila se define mediante una línea adicional en el texto. De esta manera, se pueden crear archivos CSV con gran facilidad (lo explicamos más adelante). Es por esto que los archivos .csv están asociados directamente a la creación de tablas de contenido.



Un archivo CSV suele identificarse con el programa Excel, el cual se basa en cuadrículas que conforman una tabla en filas y columnas. Lo más común es leer archivos CSV desde Excel, ya que el programa (aunque no en las versiones más antiguas) identifica automáticamente los separadores y forma la tabla sin tener que hacer nada por nuestra parte. Hay distintos separadores, usados con mayor o menor frecuencia dependiendo de la región en la que estemos. Como las tablas se usan mayoritariamente para almacenar valores numéricos, hay conflictos entre los formatos decimales de Europa (que se usan comas) con los separadores de coma. Es por ello que en Europa suele usarse el punto y coma, mientras que en EEUU y otros países de habla inglesa suele utilizarse la coma, ya que ellos usan el punto como formato decimal.

Los archivos CSV sirven para manejar una gran cantidad de datos en formato tabla, sin que ello conlleve sobrecoste computacional alguno. Es tremendamente sencillo generar una tabla a partir de un documento de texto, con tan solo delimitar cada celda requerida con un punto y coma (en el caso de Europa) o con una coma (en países de habla inglesa).

Esto es más fácil de visualizar con un ejemplo, en un bloc de notas vacío puedes insertar los caracteres que quieras y guardarlo como .txt, luego se leerá como documento de texto habitual. Si esos caracteres (o palabras completas, valores, símbolos...) los separas mediante punto y coma y guardas el archivo como .csv, al abrirlo verás que cada palabra separada del resto por punto y coma se sitúa en una celda independiente. Si ahora en ese mismo archivo de texto introduces una segunda línea y procedes como en la primera, al guardarlo como .csv y abrirlo verás que ahora tienes una tabla de dos filas y varias columnas. Así se puede crear un archivo CSV sin necesidad de software adicional. El siguiente paso habitualmente es convertir ese CSV a Excel.